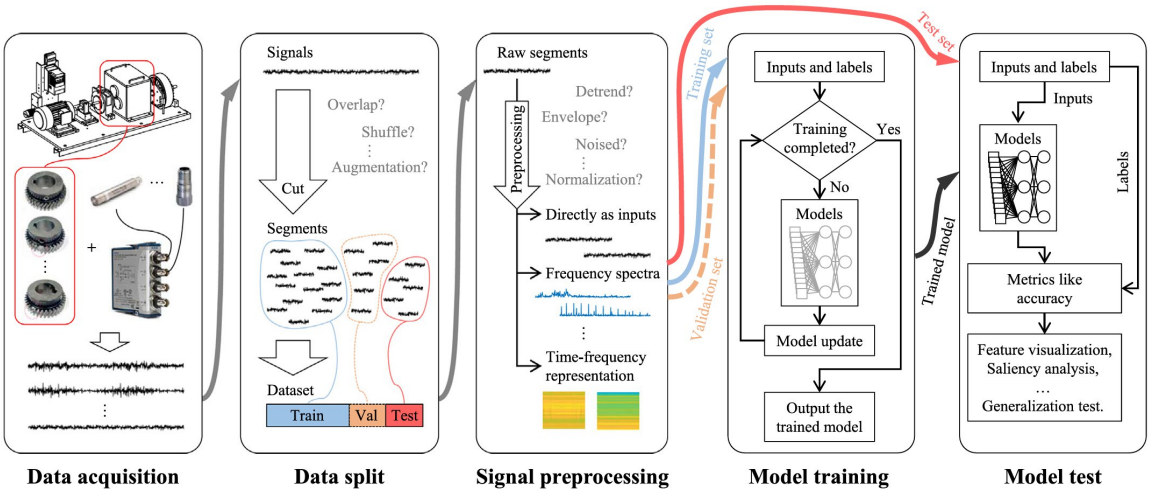

Fig. 2. A common workflow of fault diagnosis tasks through DL models, i.e., IFD.

机械信号 → 切成样本 → 预处理 → 训练模型 → 测试模型。

上图为标准检测流程

1. 三轴振动信号

振动侧采用三轴加速度传感器采集 x(t)、y(t)、z(t) 三个方向的时序信号。为了统一描述三轴综合振动强度，可构造合成振动幅值：

$$a(t) = \sqrt{x(t)^2 + y(t)^2 + z(t)^2}$$

在每个时间窗口内，常用的时域特征之一为 RMS，其定义为：

$$\mathrm{RMS} = \sqrt{\frac{1}{N}\sum_{n=1}^{N} x_n^2}$$

其中：

- N：窗口内采样点数
- x_n：第 n 个采样点的振动幅值

2. 振动频域分析（FFT）

对窗口内振动信号进行频谱分析时，通常采用离散傅里叶变换：

$$X[k] = \sum_{n=0}^{N-1} x[n] e^{-j2\pi kn/N}$$

在得到频谱后，可提取主频、频带能量与频谱熵等特征。其中，频带能量可表示为：

$$E_{[f_1, f_2]} = \sum_{f_k \in [f_1, f_2]} A[k]^2$$

频谱熵可表示为：

$$p_k = \frac{A[k]}{\sum_k A[k]}, \quad H = -\sum_k p_k \log p_k$$

上述特征可用于刻画振动信号的能量分布与频谱复杂度。

3. 视觉位移序列分析

视觉侧通过特征点跟踪获得 ROI 中的位移序列 d_x[n] 和 d_y[n]。在每个窗口内，对位移序列进行频谱分析，可获得窗口级视觉特征。

如果采用 Welch 方法估计功率谱密度，则可表示为：

$$P_{xx}(f) = \frac{1}{K} \sum_{m=1}^{K} \frac{1}{U} \left| \sum_{n=0}^{L-1} w[n] x_m[n] e^{-j2\pi fn} \right|^2$$

其中：

- K：分段数量
- L：每段长度
- w[n]：窗函数
- U：归一化因子

在得到 d_x 和 d_y 的频谱后，可提取：

- 主频
- 峰值功率
- 频带能量
- 频谱重心
- 频谱熵

4. 自监督 / 对比学习

对比学习通过构造同一样本的不同增强视图来学习稳定表示。设两个增强视图经过编码器和投影头后的输出分别为：

$$z_i = g(f(x_i)), \quad z_j = g(f(x_j))$$

则 NT-Xent 损失可写为：

$$\ell_{i,j} = -\log \frac{\exp(\mathrm{sim}(z_i, z_j)/\tau)}{\sum_{k \neq i} \exp(\mathrm{sim}(z_i, z_k)/\tau)}$$

该损失的目标是拉近同一样本不同视图之间的距离，并拉远不同样本之间的距离。

5. 域适应 / 域泛化

为解决不同工况下的数据分布差异问题，可引入域适应 / 域泛化方法。以 Deep CORAL 为例，其域对齐损失为：

$$L_{\text{CORAL}} = \frac{1}{4d^2} \| C_s - C_t \|_F^2$$

该损失用于减小源域与目标域特征协方差之间的差异，从而提高模型在新工况下的稳定性。

6. 最终决策模型

在完成视觉特征与振动特征提取后，可将两路特征拼接成最终输入向量，并送入分类模型：

$$\mathbf{x}_{\text{final}} = [\mathbf{v}_i; \mathbf{s}_i], \qquad \hat{y}_i = F(\mathbf{x}_{\text{final}})$$

其中，F(·) 表示最终决策模型，例如 XGBoost 或小型 MLP。